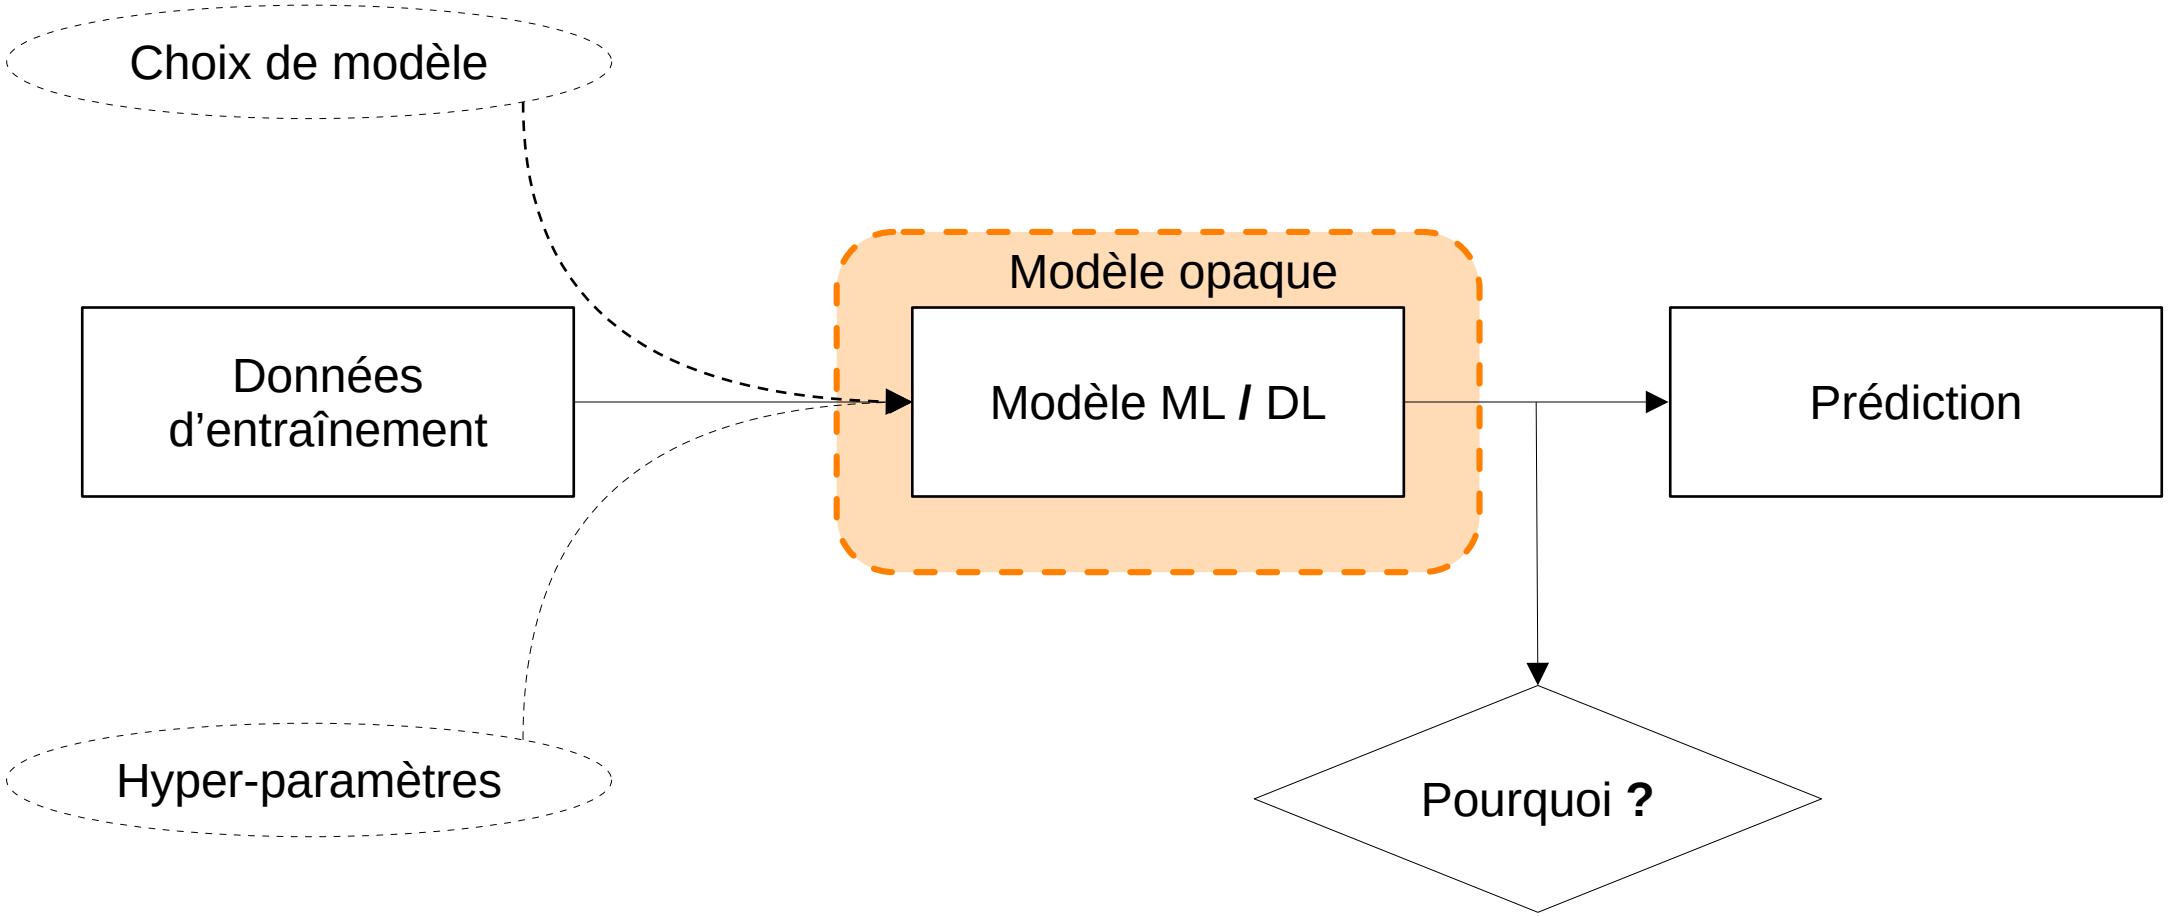
Journée des Thèses DILS
27 et 28 juin 2024

Explications de confiance pour l'intelligence artificielle

Jules Soria (8 mois, Université Paris-Saclay, ED STIC – pôle C)
Encadrants de thèse :
Zakaria Chihani – DILS / LSL / AISER
Julien Girard-Satabin – DILS / LSL / AISER
Romain Xu-Darme – DILS / LSL / AISER
Directrice de thèse :
Daniela Cancila - DSCIN

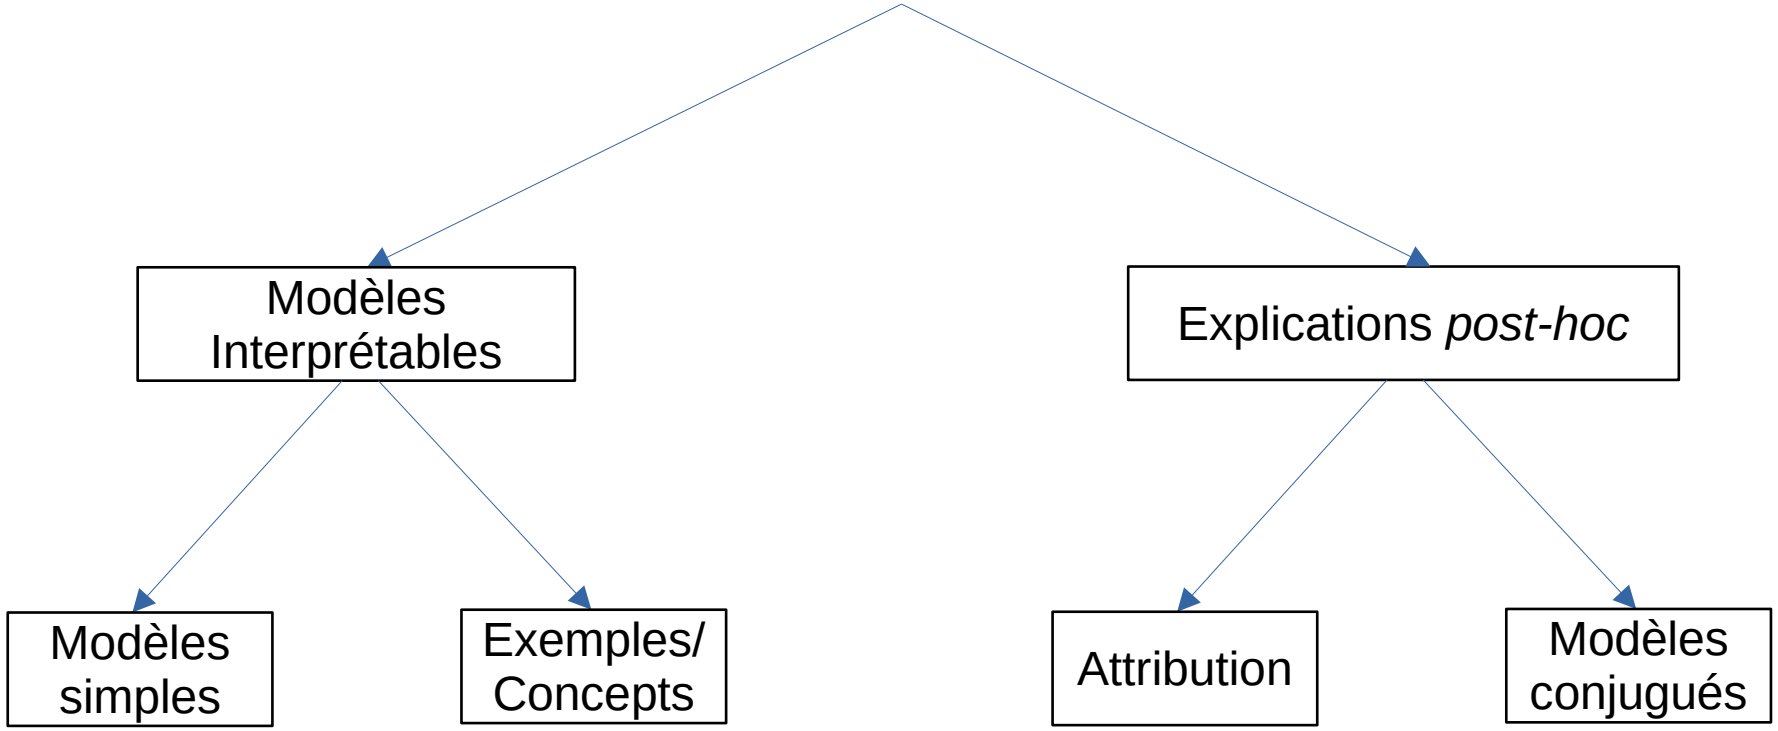
Contexte général

- *Les explications en IA : comprendre des modèles opaques*



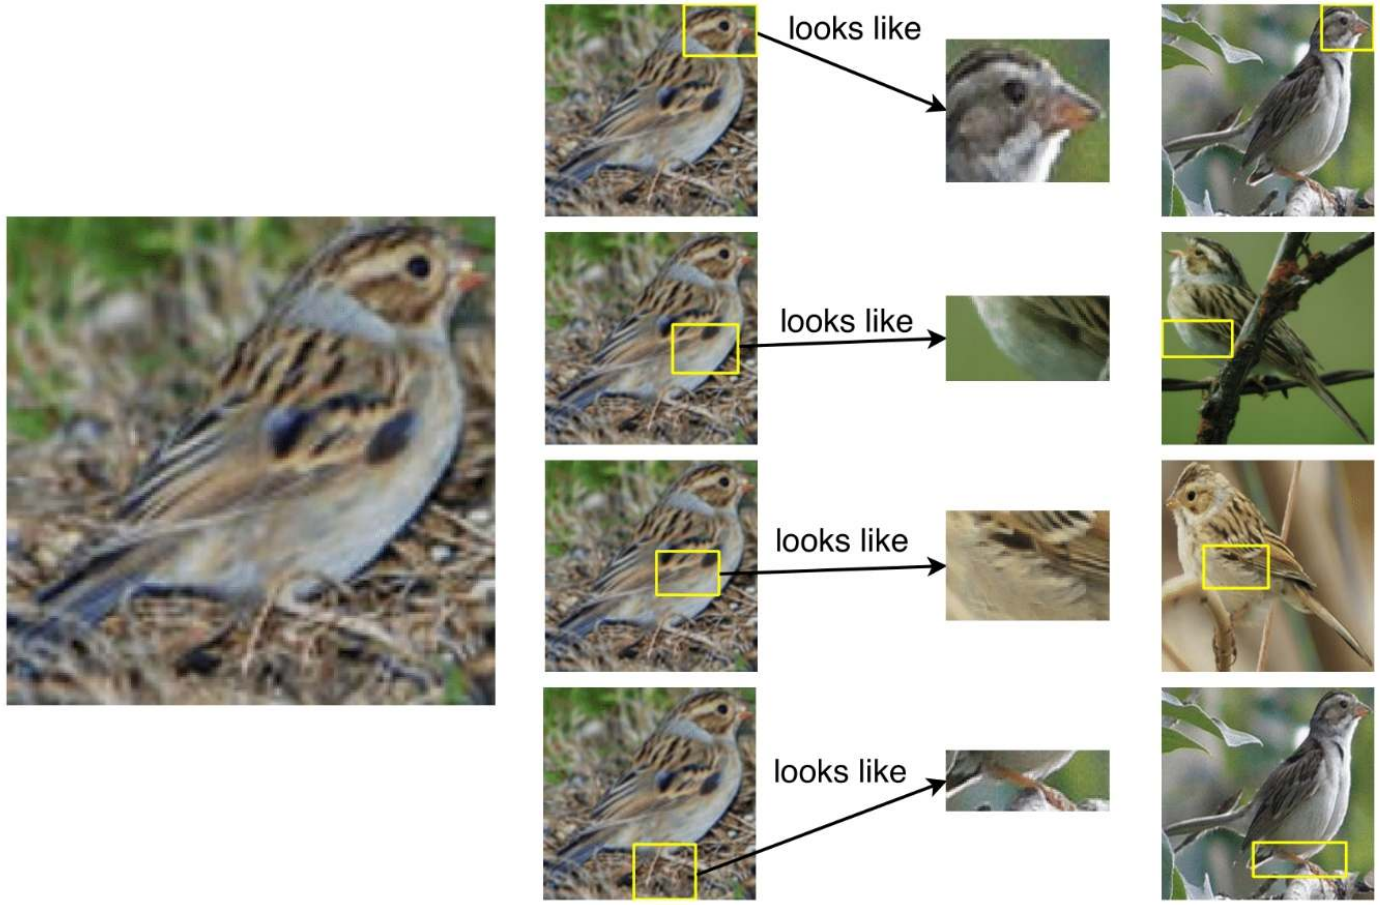
Contexte général

- *Les explications en IA : quels types d'explications ?*



Contexte général

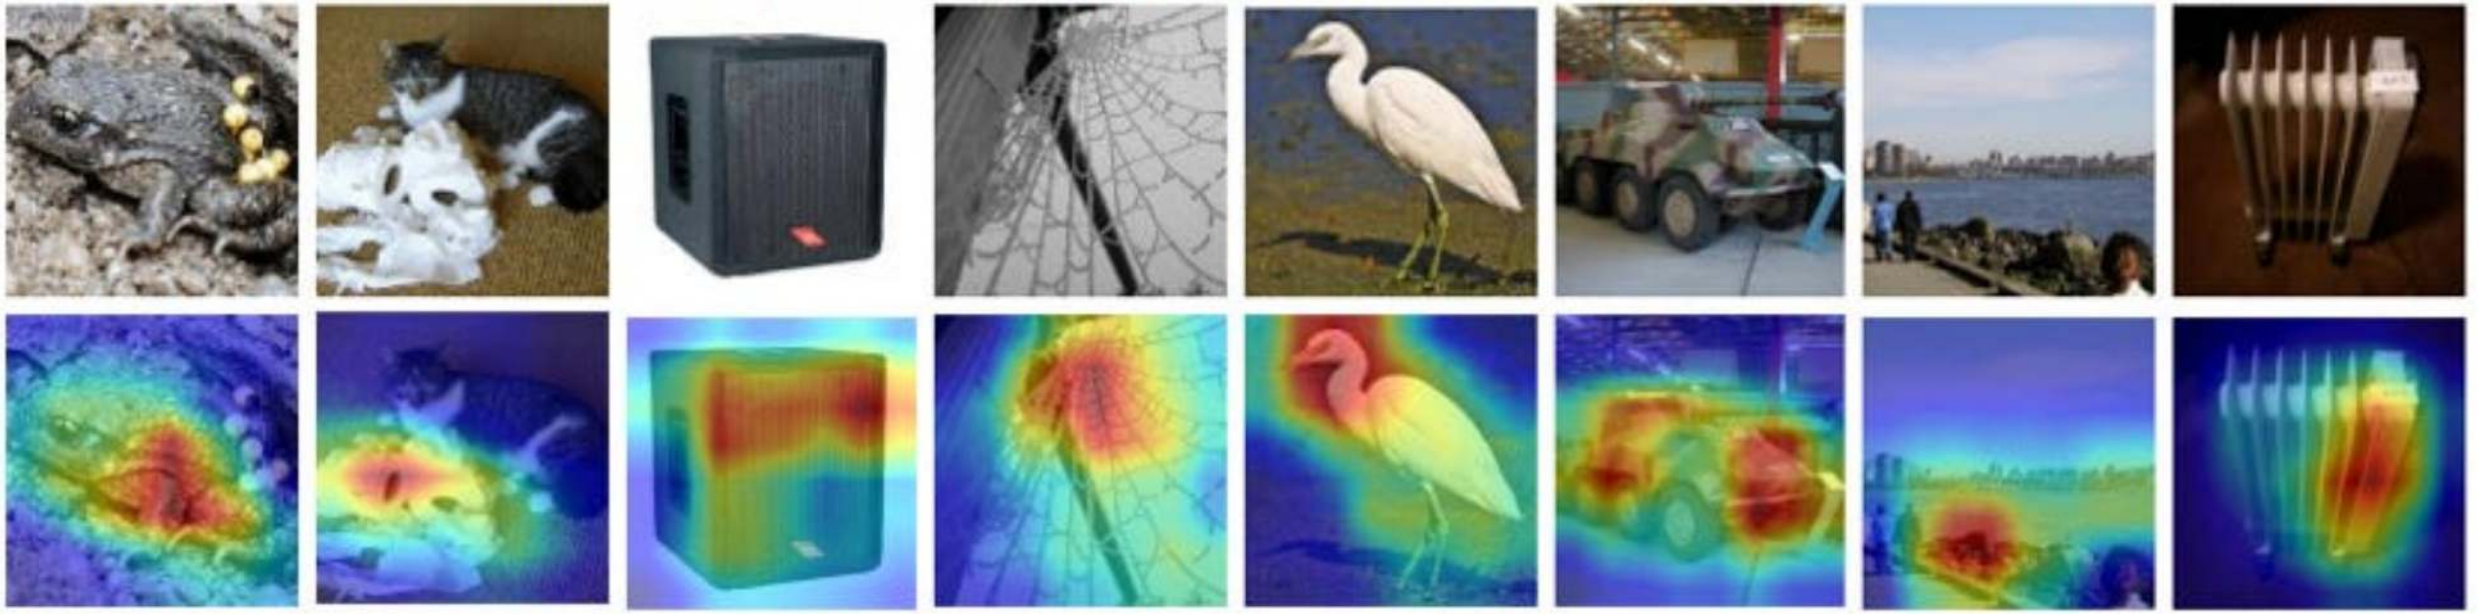
- *Les explications par prototypes : une approche pour des modèles interprétables*



Chen, Chaofan, et al. "This looks like that: deep learning for interpretable image recognition." Advances in neural information processing systems 32 (2019).

Contexte général

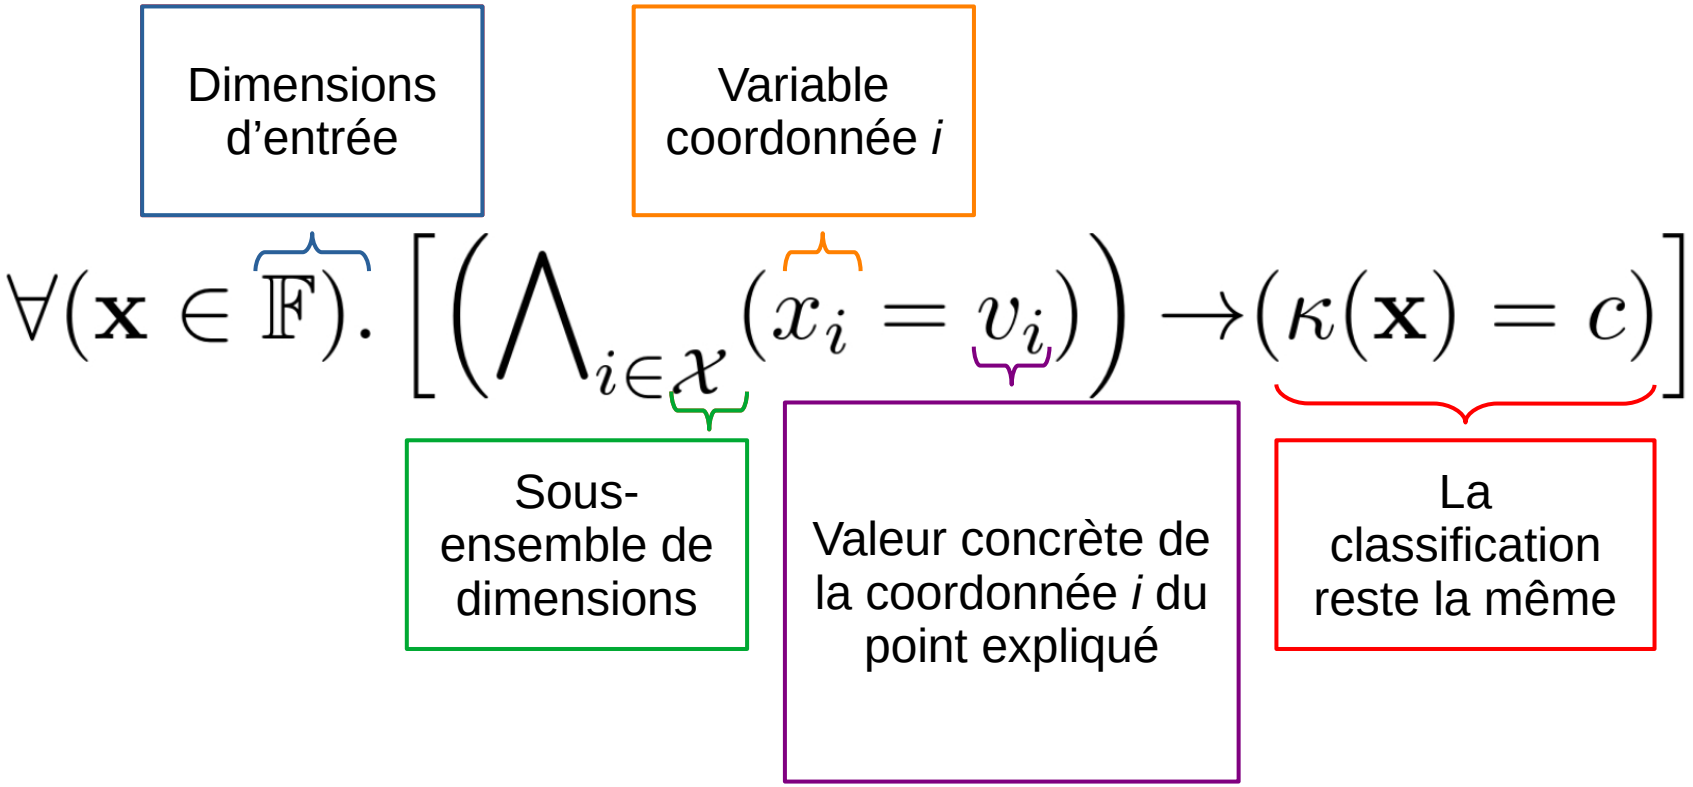
- *Les explications par attribution :*



Selvaraju, Ramprasaath R., et al. "Grad-cam: Visual explanations from deep networks via gradient-based localization."

Contexte général

- *Les explications formelles :*



Marques-Silva, Joao, and Alexey Ignatiev. "Delivering trustworthy AI through formal XAI." Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 36. No. 11. 2022.

Contexte général

- *Les explications sont manipulables :*



Dombrowski, Ann-Kathrin, et al. "Explanations can be manipulated and geometry is to blame." Advances in neural information processing systems

Sujet de thèse

- *Croître la confiance dans les systèmes à bases de composantes d'intelligence artificielle en :*
  - *Étudiant comment les explications peuvent être un moyen d'attaquer et de défendre un modèle*

    → **Question de recherche 1 :** *Peut-on perturber une image de manière imperceptible de façon à ce que la classification change, mais que l'explication soit elle-même perturbée de manière imperceptible ?*
  - *Expliquant les modèles opaques de manière formelle*

    → **Question de recherche 2 :** *À quoi ressemblerait une explication minimale abductive dans le cadre de modèles à bases de prototypes ? Comment peut-on les trouver et les construire ?*
  - *Étendant la modalité et le domaine des explications*

    → **Question de recherche 3 :** *Peut-on étendre l'attribution abstraite de « features » à d'autres types de données (images, texte, …) et pourrait-on l'appliquer à des réseaux de neurones ?*

Avancement des travaux

- ***Travaux réalisés*** *:*
  - *Élaboration de deux protocoles d'attaque :*
    - *Un moyen de trouver la meilleure classe à cibler*
    - *Une résolution d'un problème d'optimisation pour minimiser la distance entre deux cartes de salience*
      - → *Journée GDR RADIA - GT EXPLICON - XAI4U (30/05/2024)*
      - → *Workshop Fondements Mathématiques de l'IA (17/06/2024)*
- ***Travaux prévus*** *:*
  - *Finaliser (publier) les travaux sur les attaques adversariales qui surmontent les explications.*
  - *Explorer à quoi ressembleraient des explications abductives minimales dans le cadre des modèles à prototypes, et les implémenter.*
  - *Explorer comment étendre l'attribution de features par interprétation abstraite à des réseaux de neurones artificiels.*