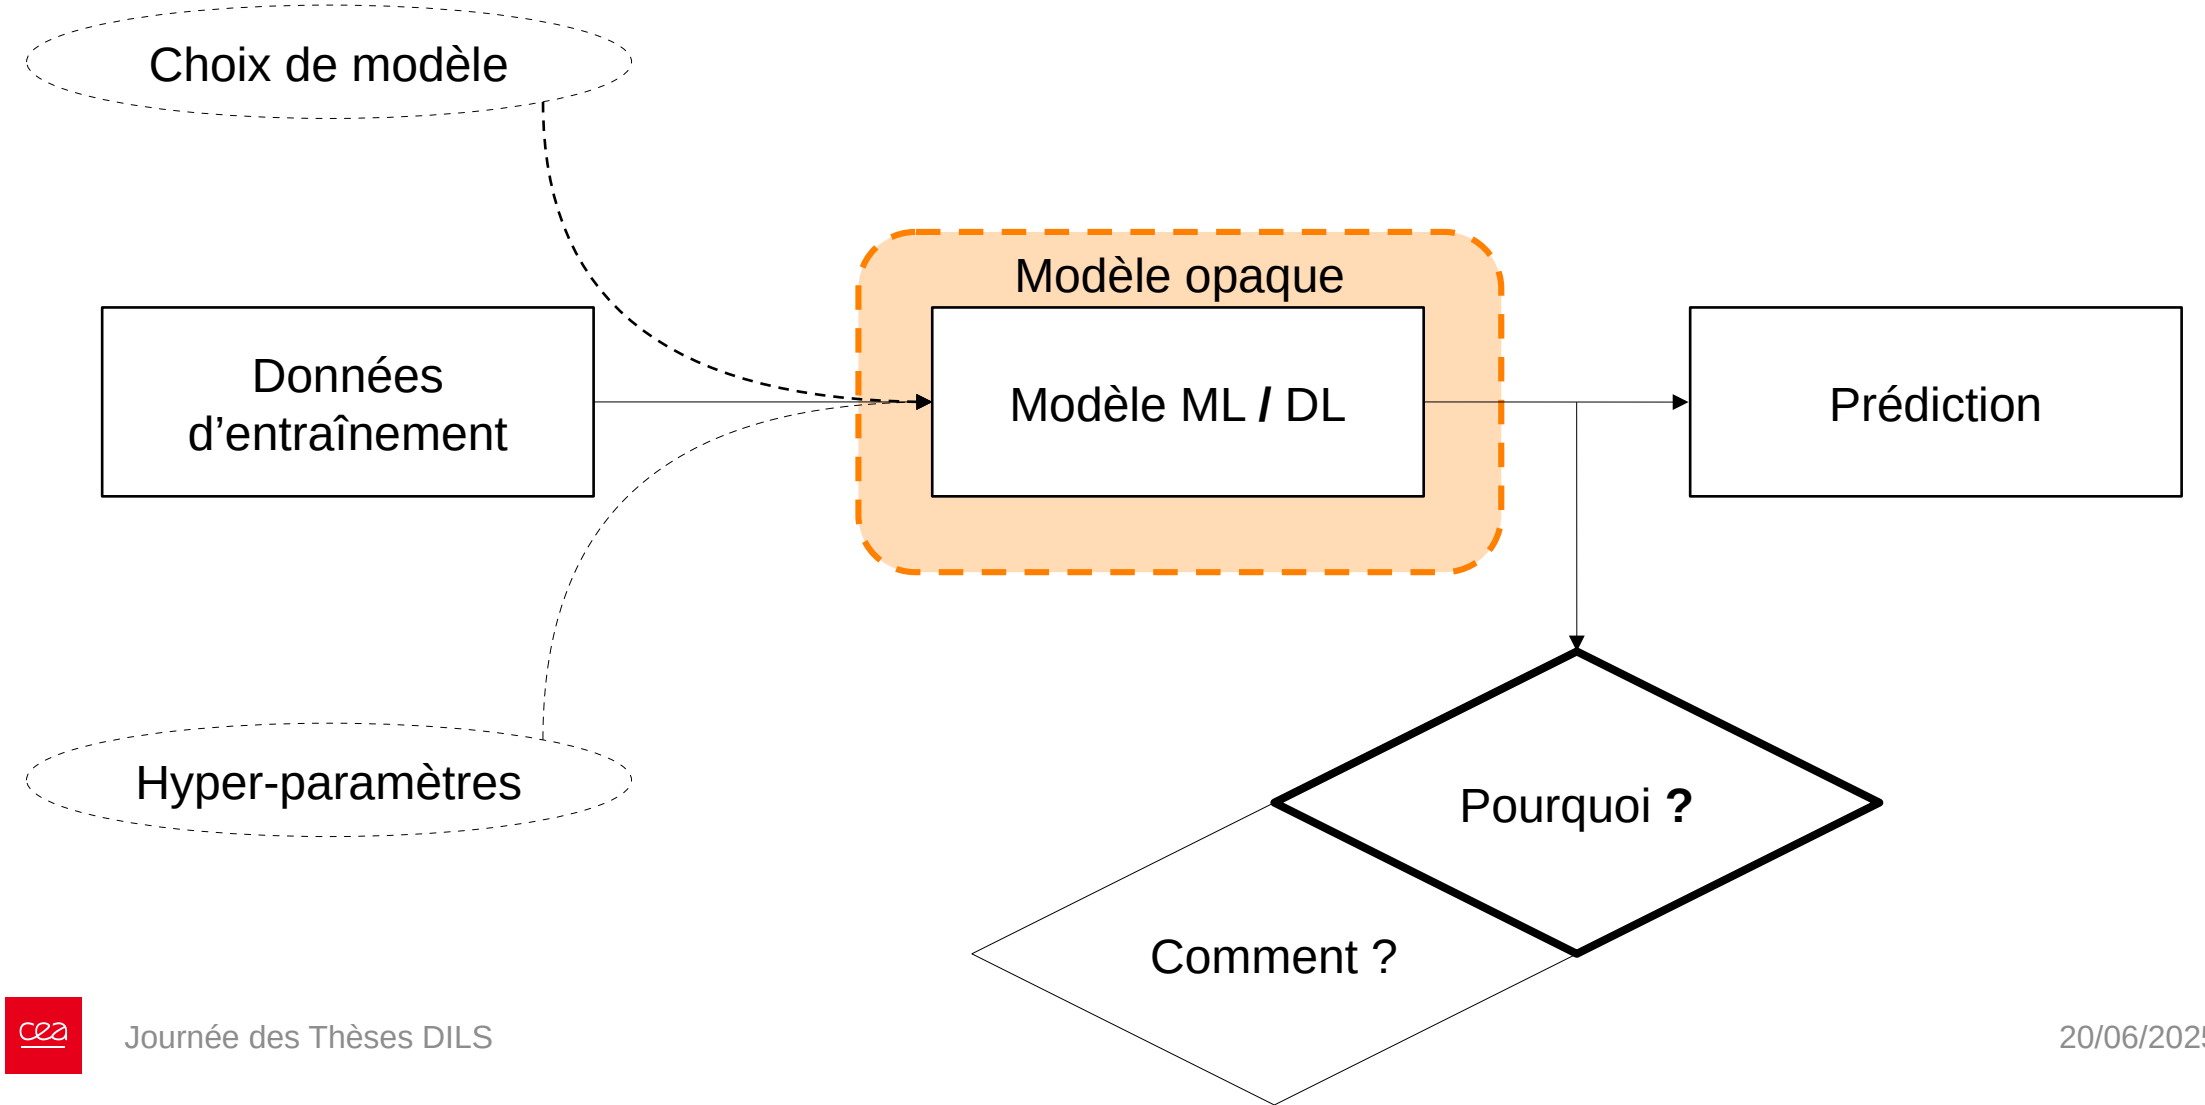
Journée des Thèses DILS
20 et 27 juin 2025

Explications de confiance pour l'intelligence artificielle

Jules Soria (15* mois, Université Paris-Saclay, ED STIC – pôle C)
Encadrants de thèse :
Zakaria Chihani – DILS / LSL / AISER
Julien Girard-Satabin – DILS / LSL / AISER
Romain Xu-Darme – DILS / LSL / AISER
Directrice de thèse :
Daniela Cancila - DSCIN

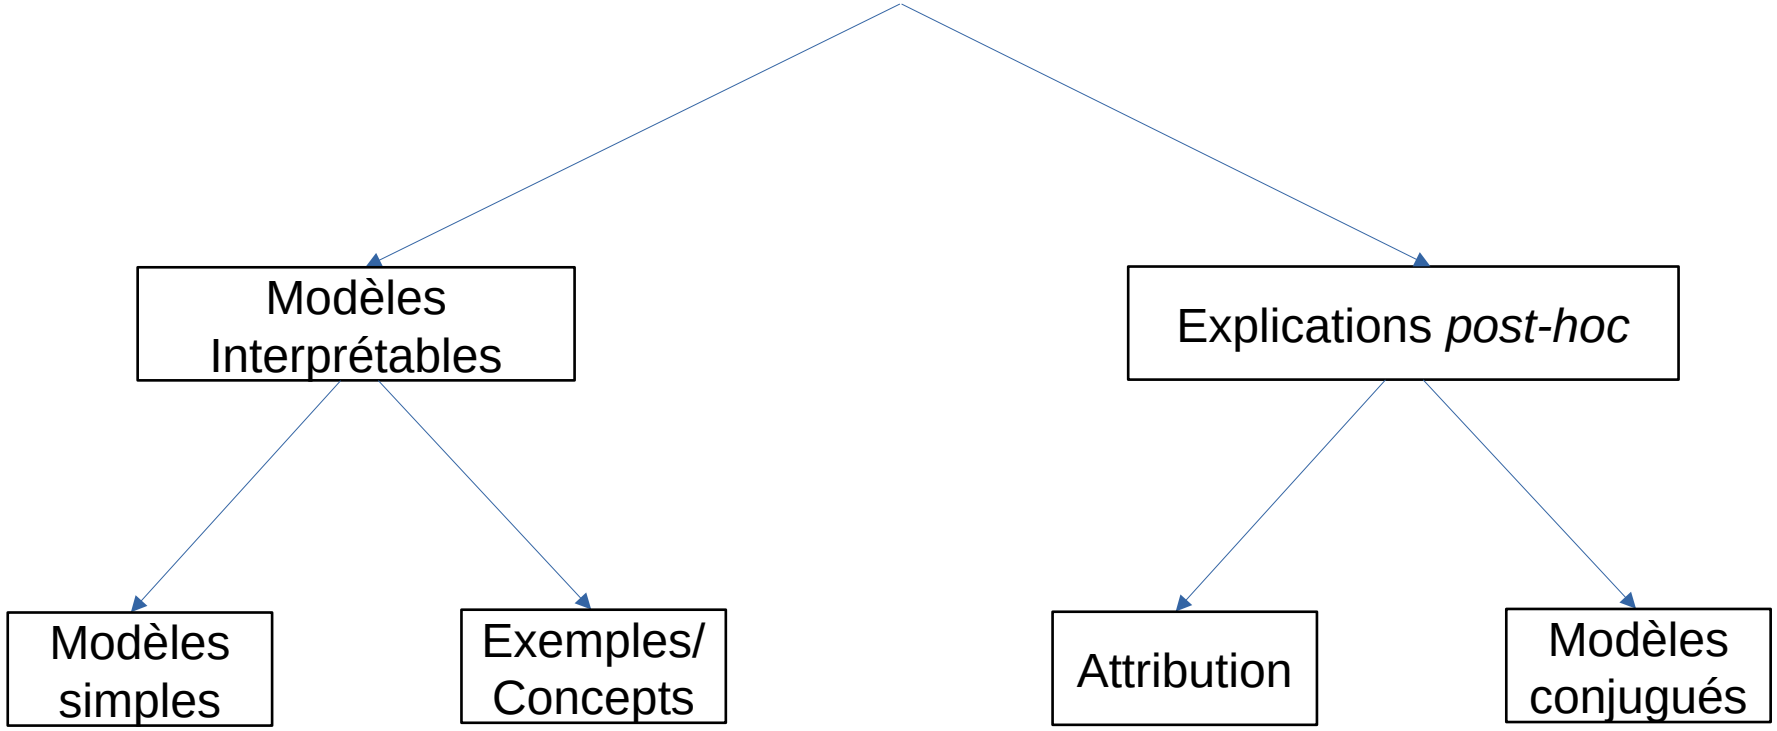
Contexte général

Les explications en IA : comprendre des modèles opaques



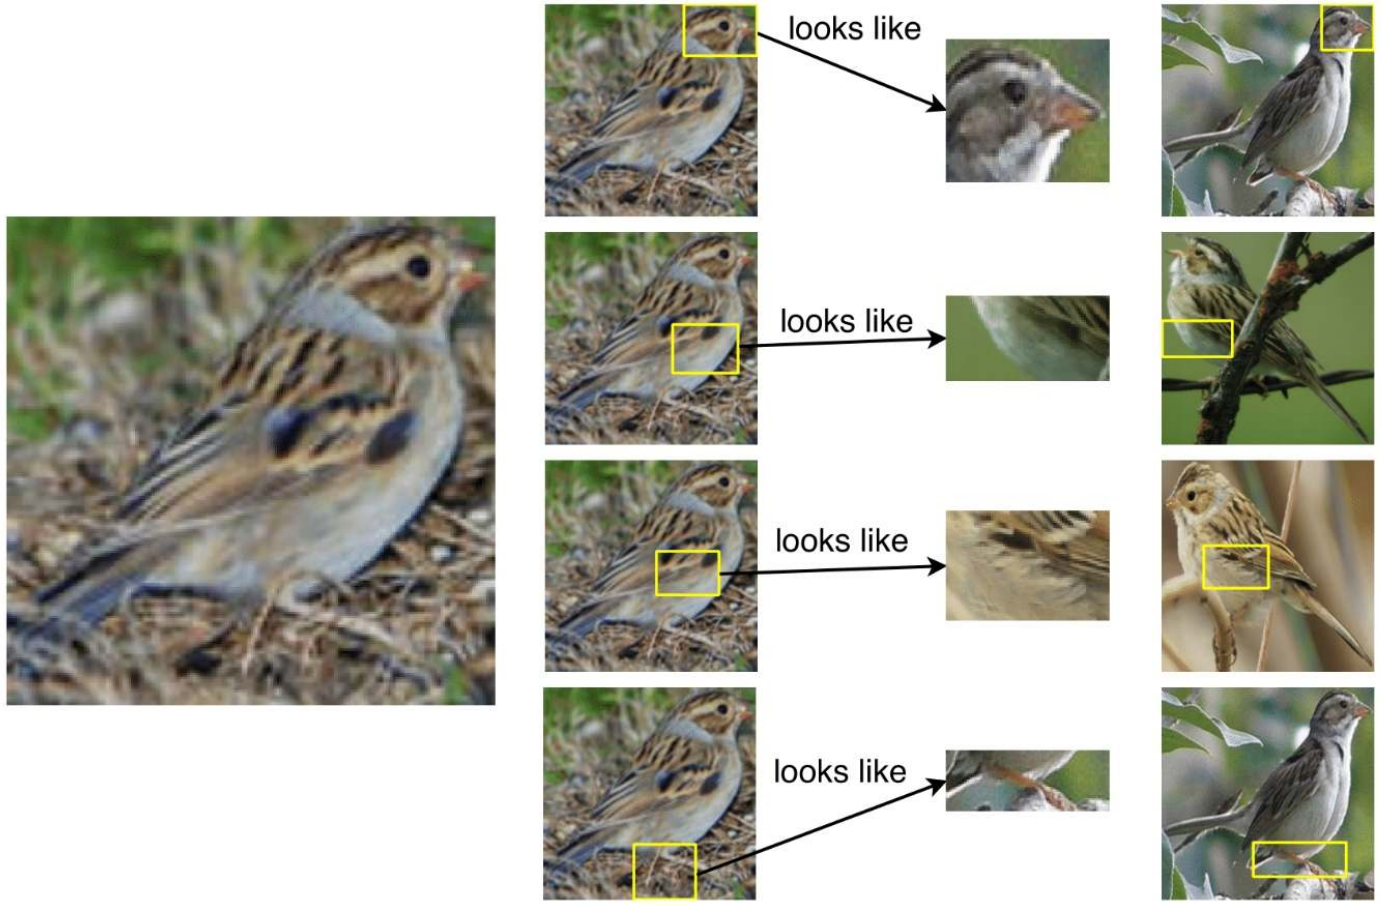
Contexte général

Les explications en IA : quels types d'explications ?



Contexte général

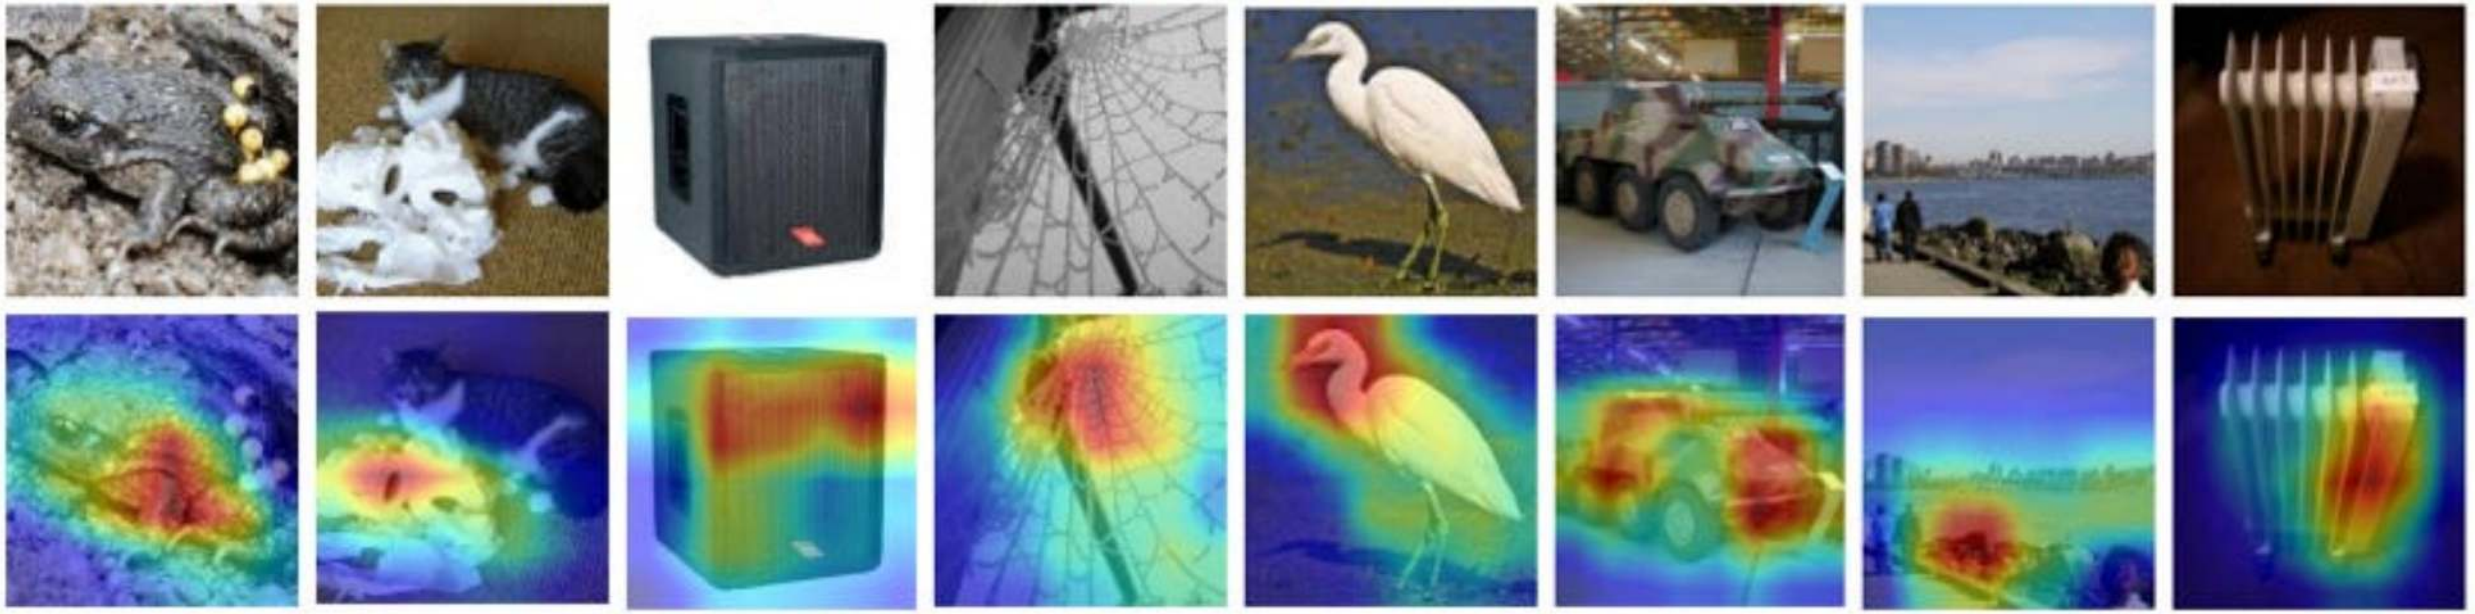
Les explications par prototypes : une approche pour des modèles interprétables



Chen, Chaofan, et al. "This looks like that: deep learning for interpretable image recognition." Advances in neural information processing systems 32 (2019).

Contexte général

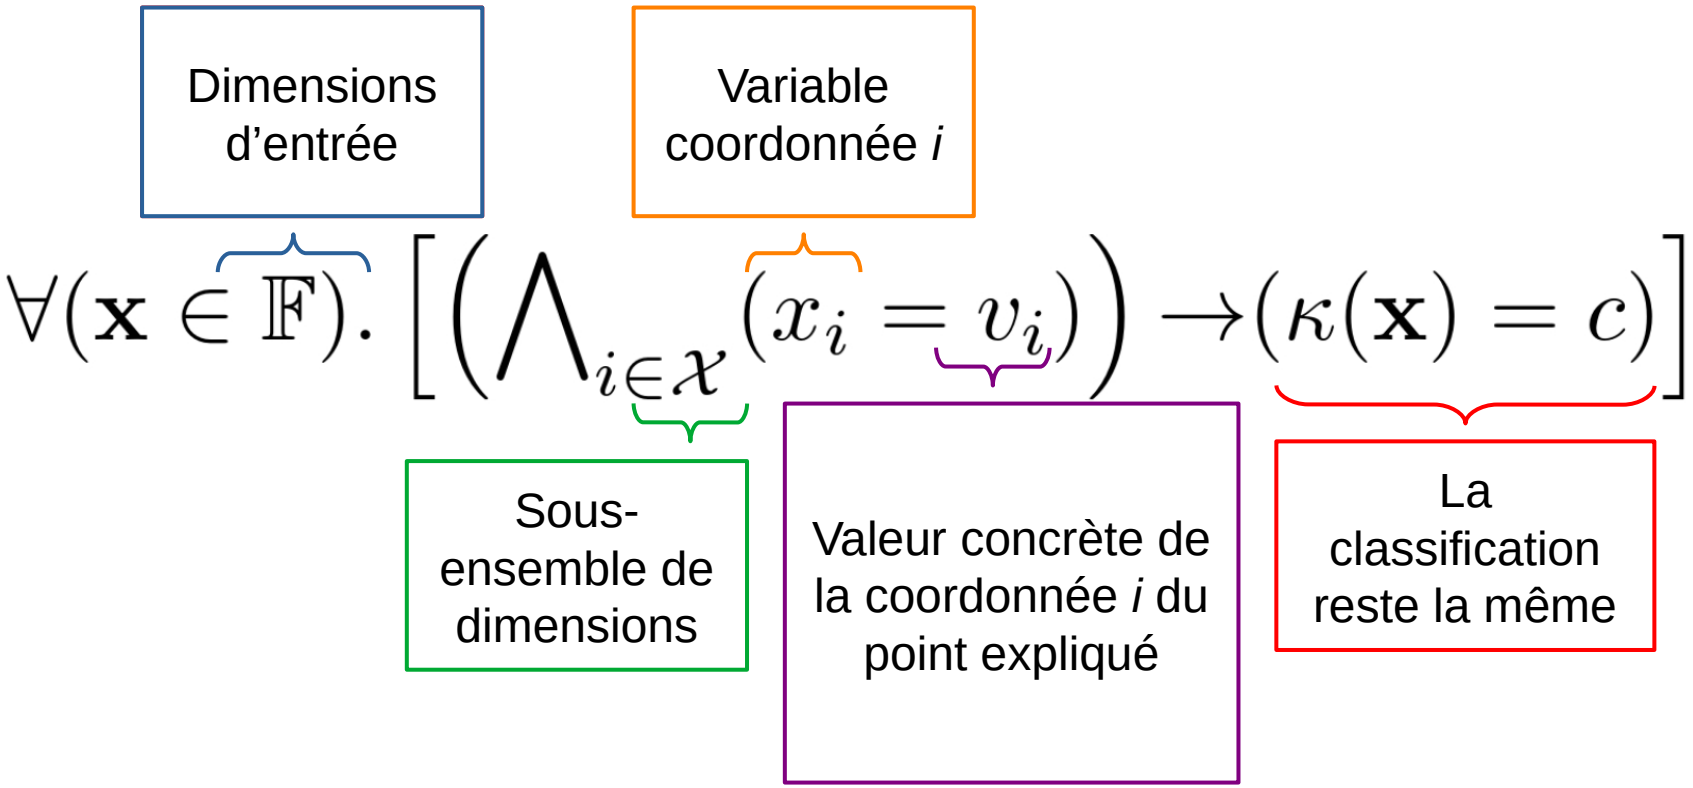
Les explications par attribution :



Selvaraju, Ramprasaath R., et al. "Grad-cam: Visual explanations from deep networks via gradient-based localization."

Contexte général

Les explications formelles :



Marques-Silva, Joao, and Alexey Ignatiev. "Delivering trustworthy AI through formal XAI." Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 36. No. 11. 2022.

Contexte général

Les explications sont manipulables :



Dombrowski, Ann-Kathrin, et al. "Explanations can be manipulated and geometry is to blame." Advances in neural information processing systems

Sujet de thèse

Croître la confiance dans les systèmes à bases de composantes d'intelligence artificielle en :

~~*Étudiant comment les explications peuvent être un moyen d'attaquer et de défendre un modèle*~~

~~→ **Question de recherche 1 :** *Peut-on perturber une image de manière imperceptible de façon à ce que la classification change, mais que l'explication soit elle-même perturbée de manière imperceptible ?*~~

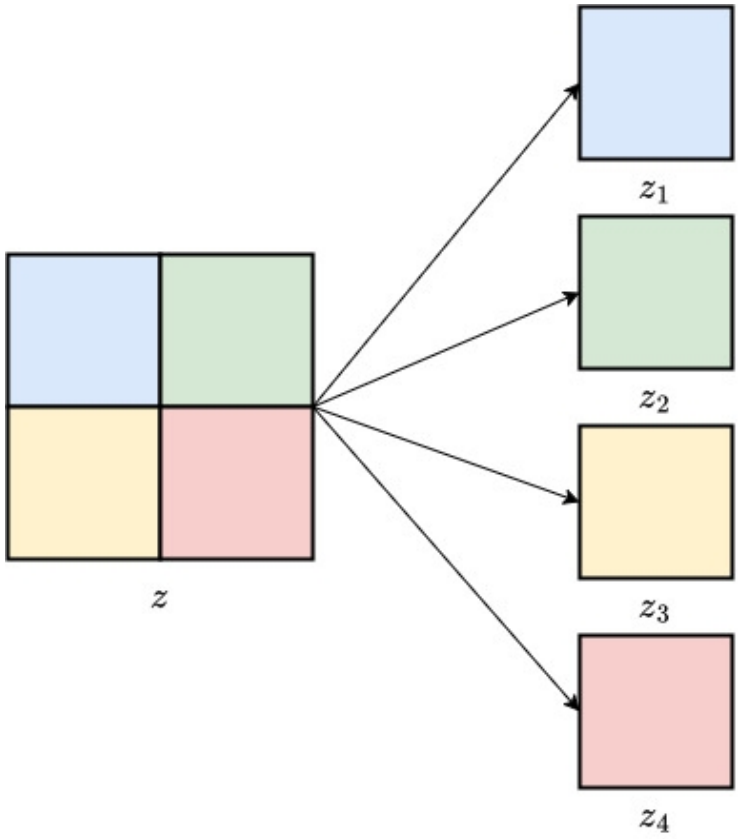
Expliquant les modèles opaques de manière formelle

→ **Question de recherche 2 :** *À quoi ressemblerait une explication minimale abductive dans le cadre de modèles à bases de prototypes ? Comment peut-on les trouver et les construire ?*

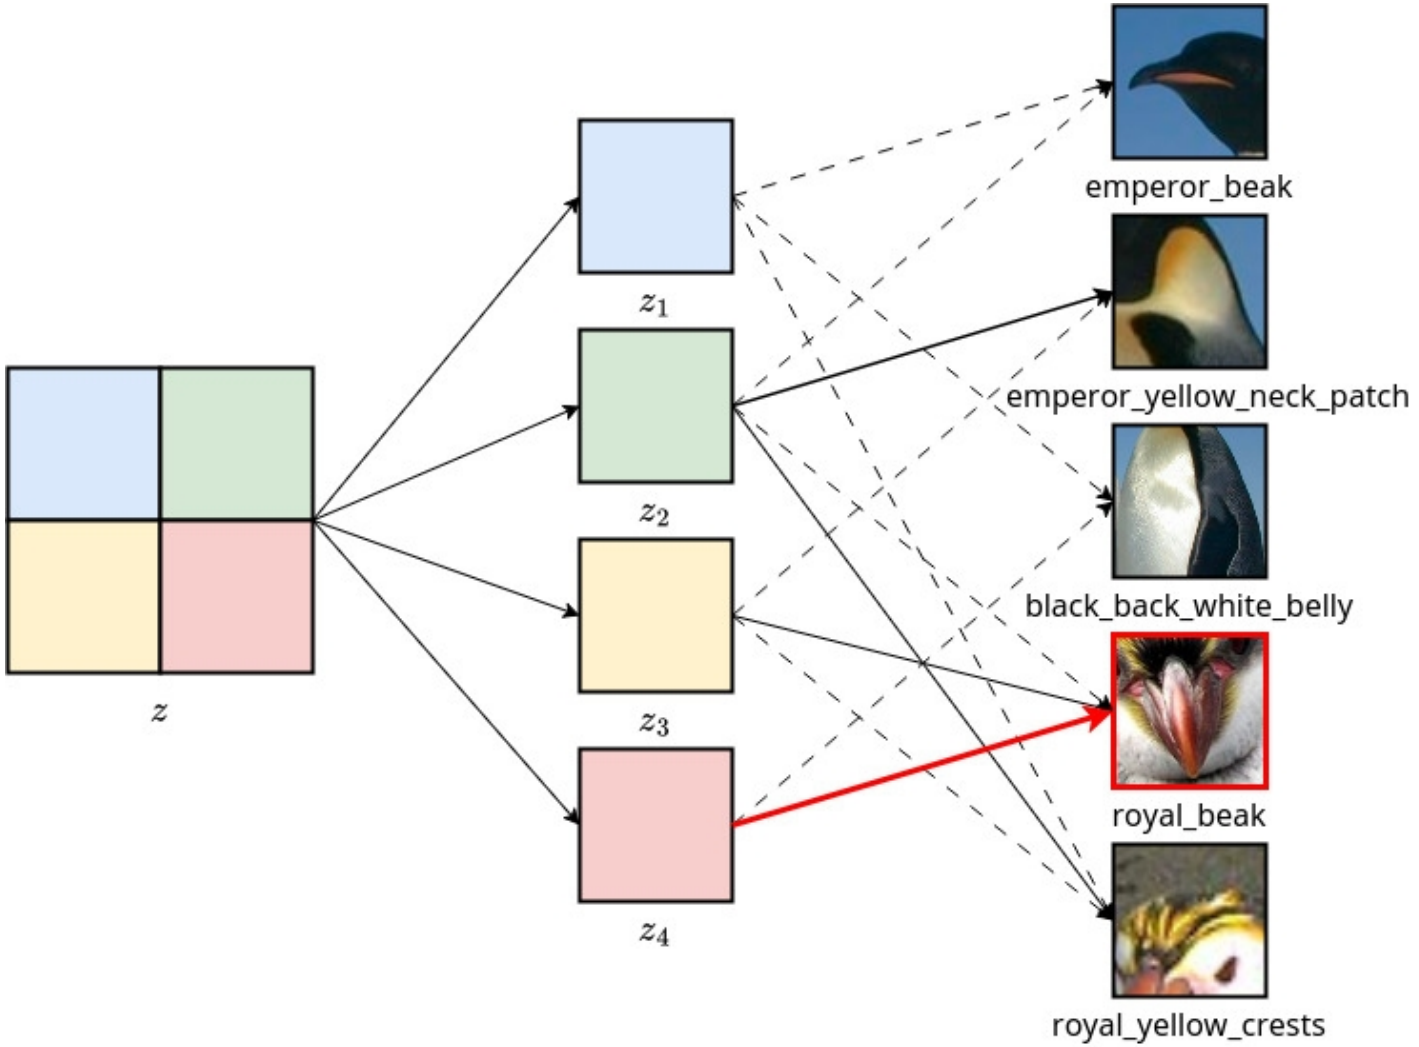
Étendant la modalité et le domaine des explications

→ **Question de recherche 3 :** *Peut-on étendre l'attribution abstraite de « features » à d'autres types de données (images, texte, …) et pourrait-on l'appliquer à des réseaux de neurones ?*

Explications Abductives pour Réseaux à base de prototypes



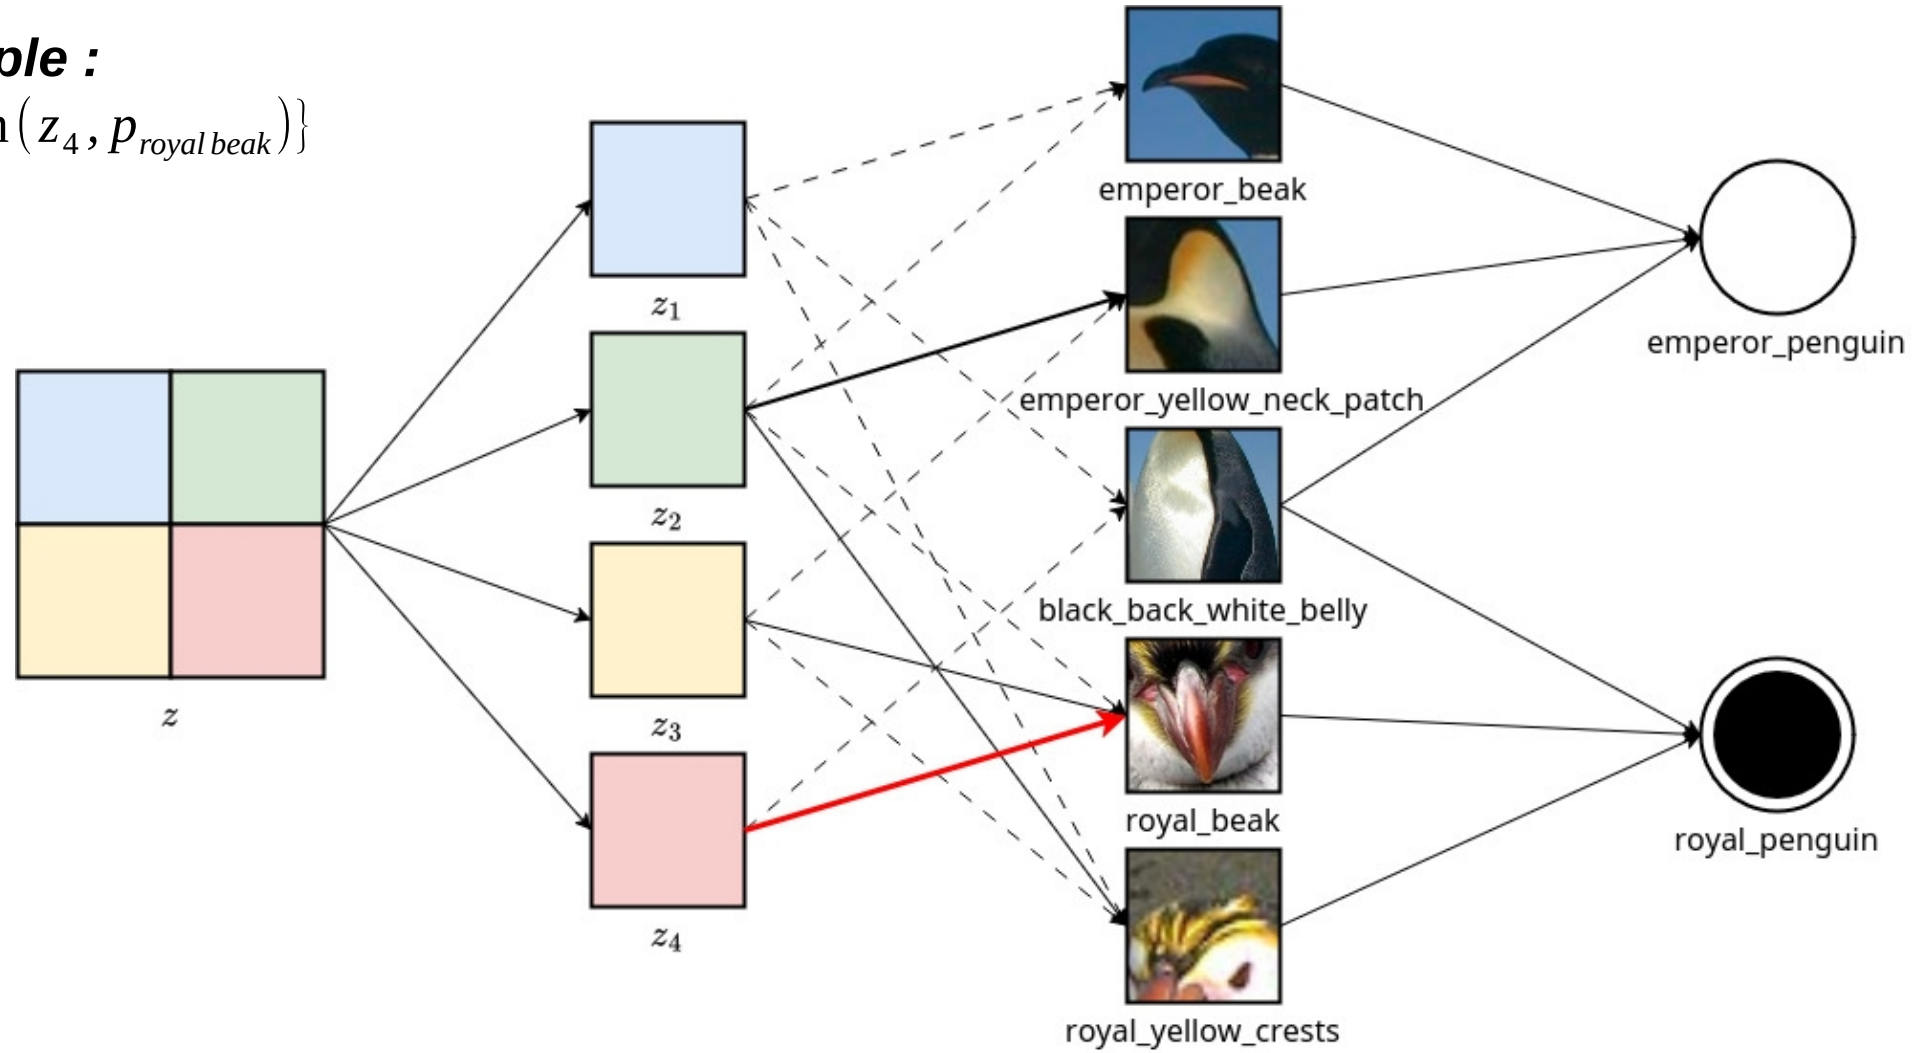
Explications Abductives pour Réseaux à base de prototypes



Explications Abductives pour Réseaux à base de prototypes

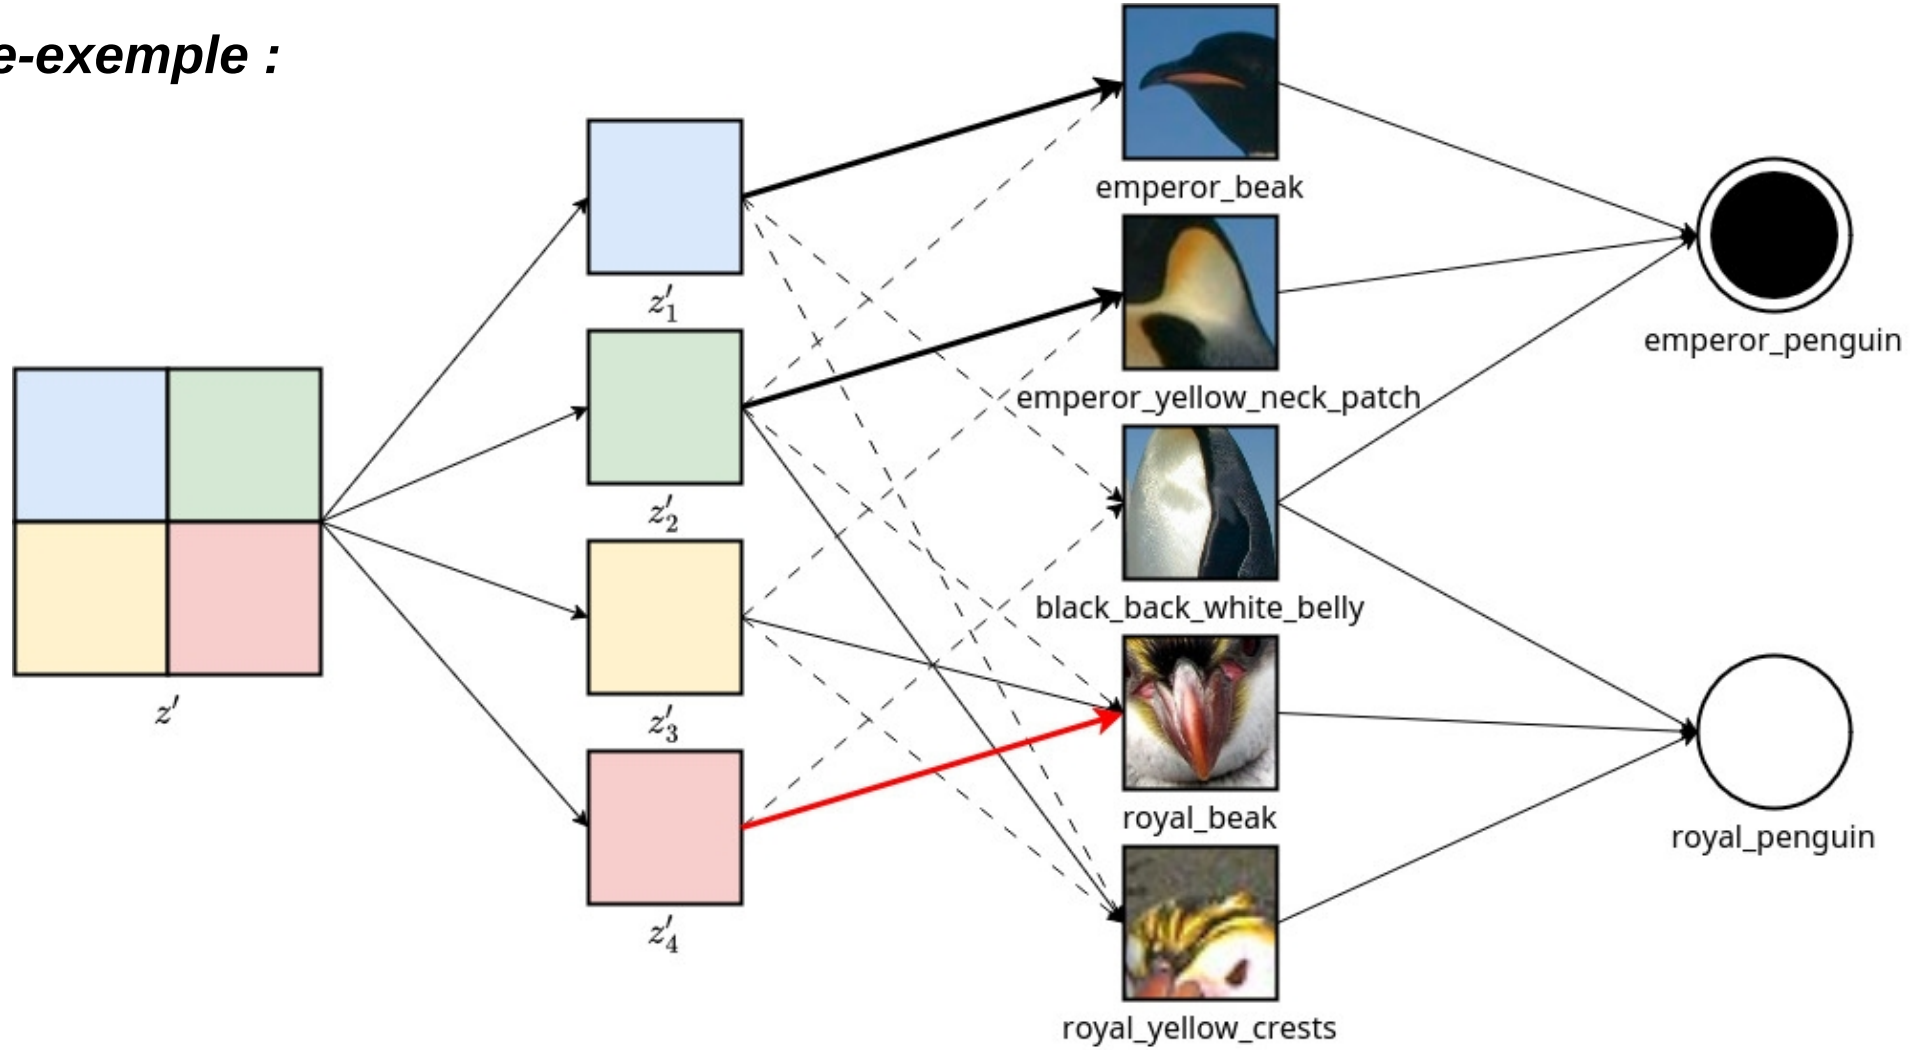
Exemple :

$\epsilon = \{\text{sim}(z_4, p_{royal\ beak})\}$



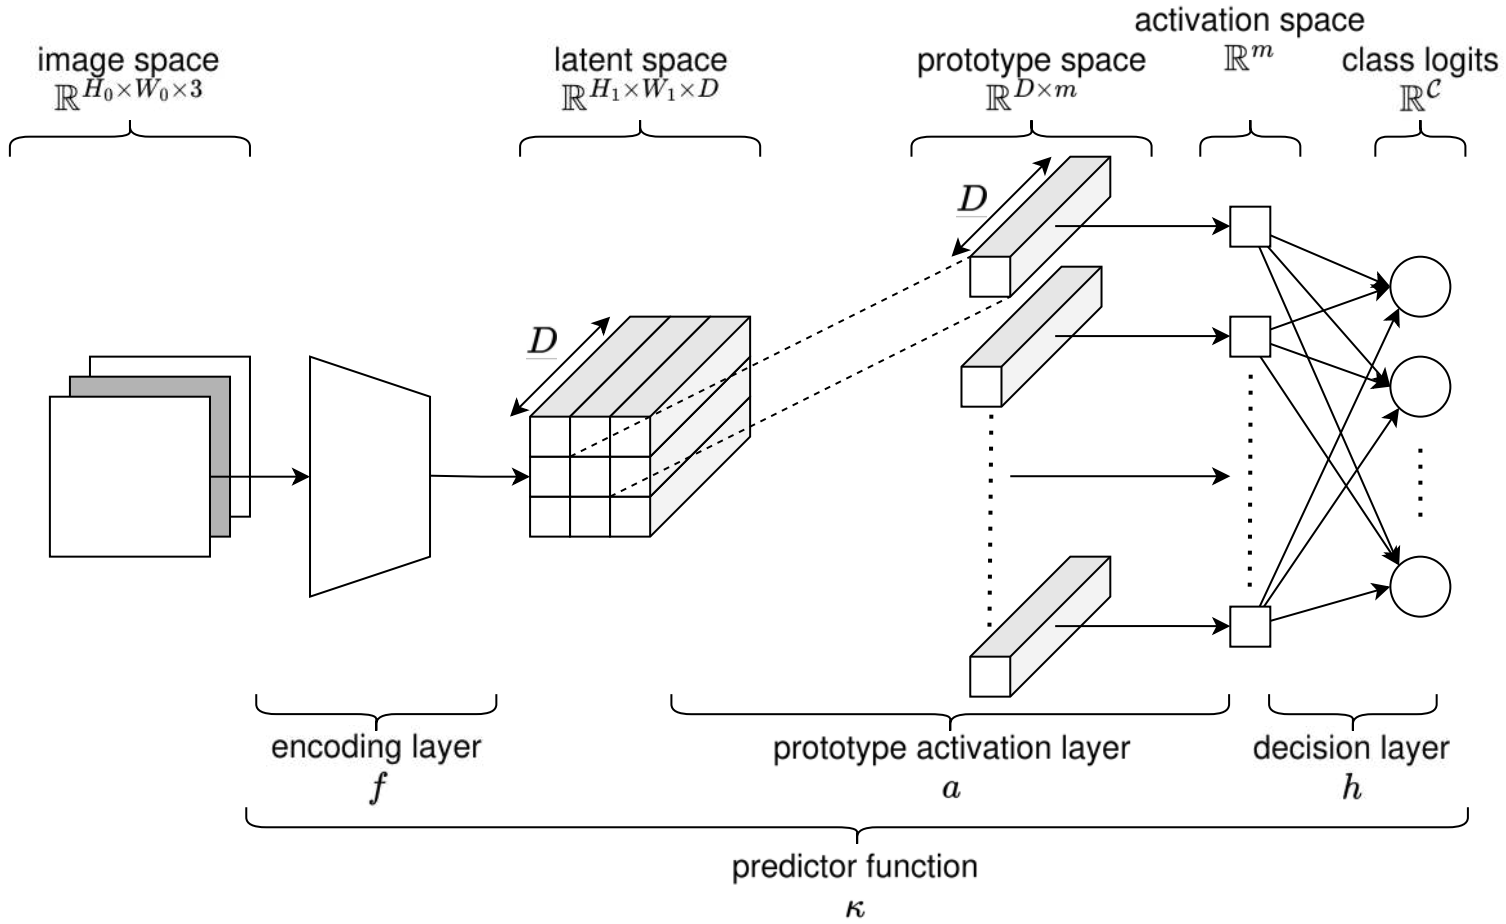
Explications Abductives pour Réseaux à base de prototypes

Contre-exemple :



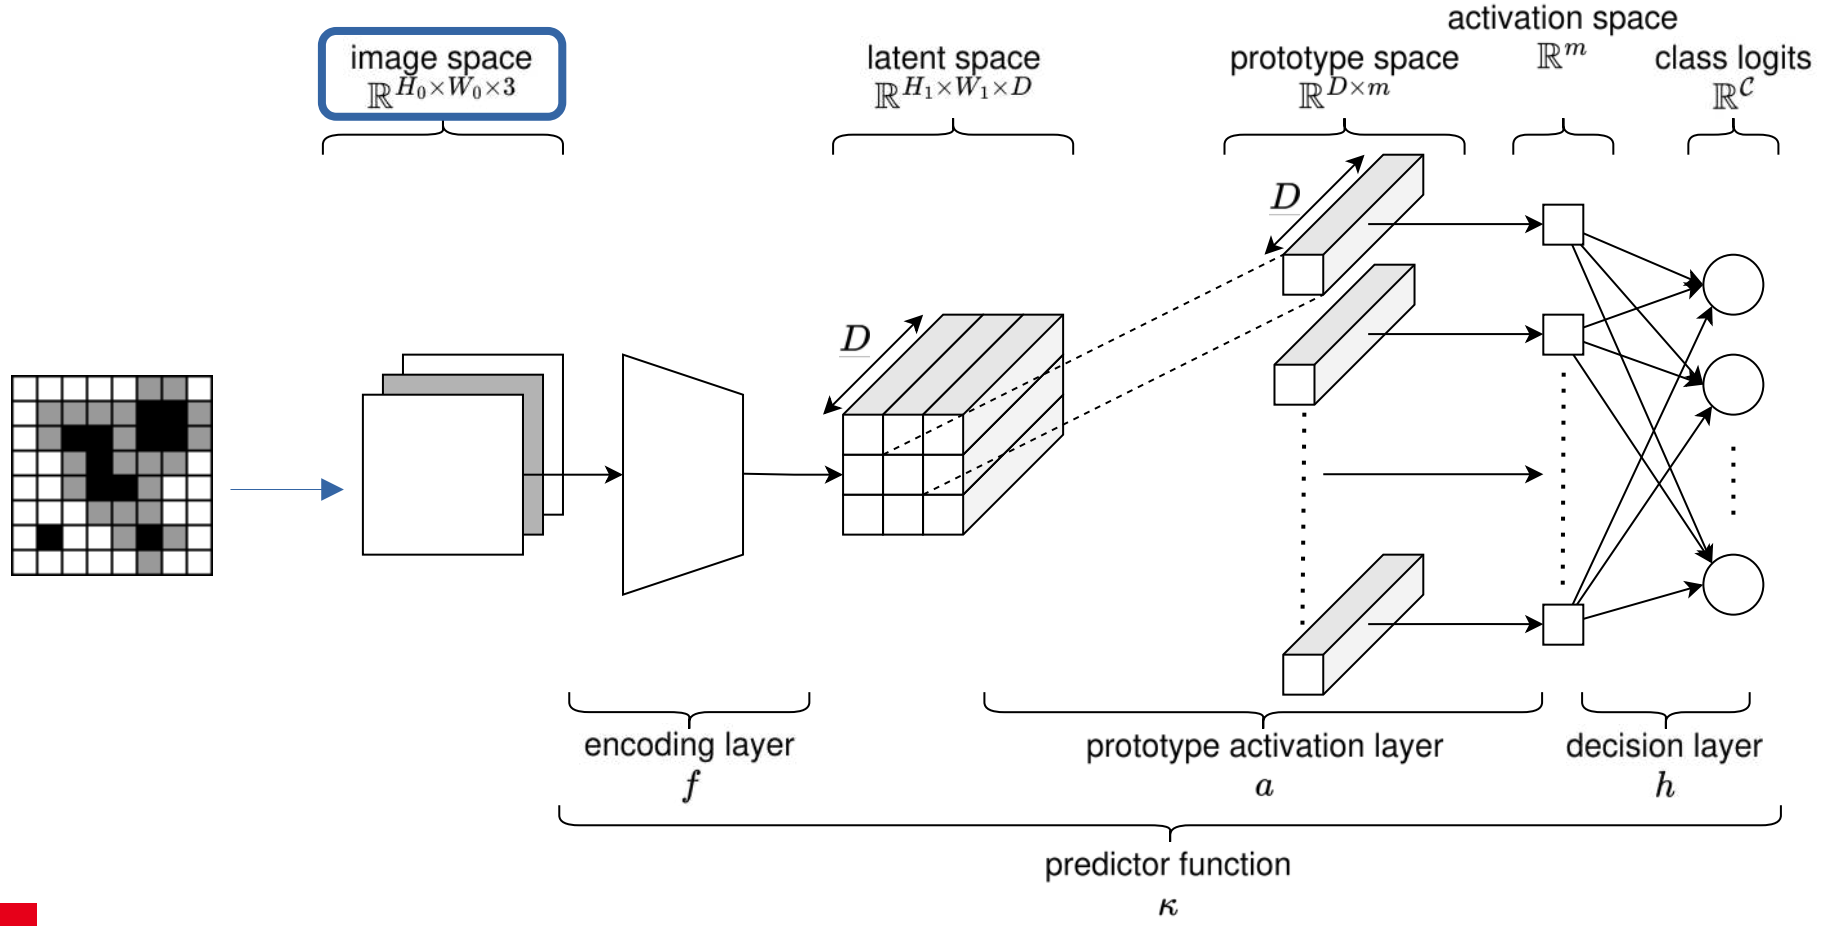
Explications Abductives pour Réseaux à base de prototypes

L'architecture permet de produire des explications dans différents espaces :



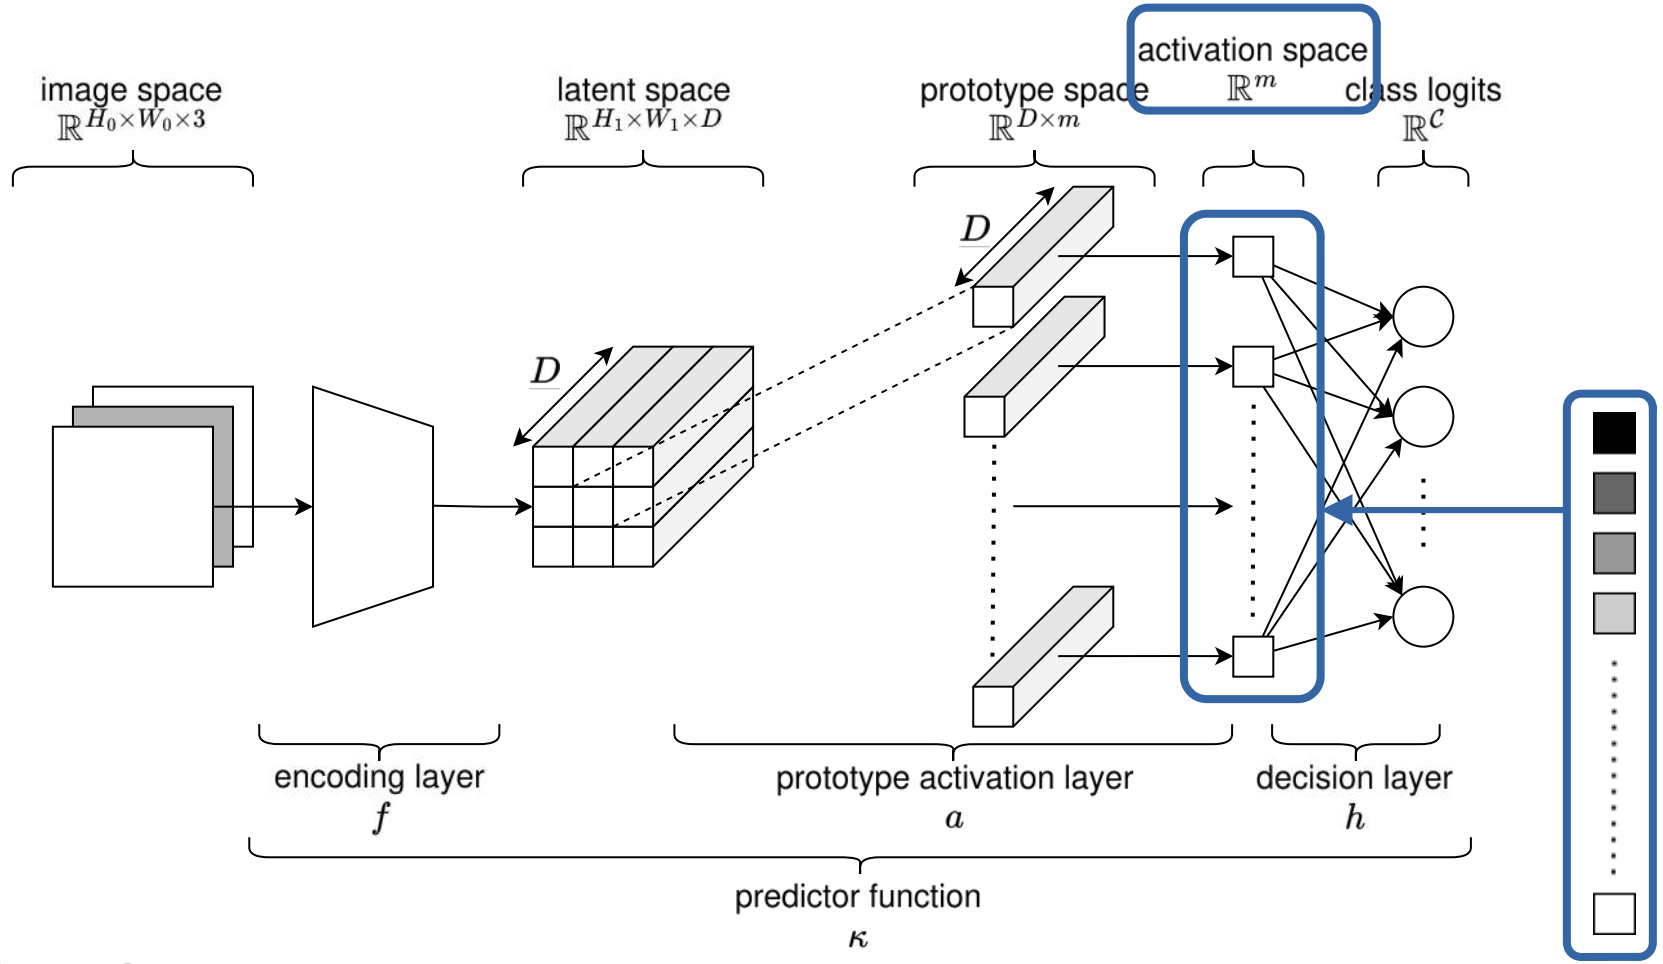
Explications Abductives pour Réseaux à base de prototypes

L'architecture permet de produire des explications dans différents espaces :



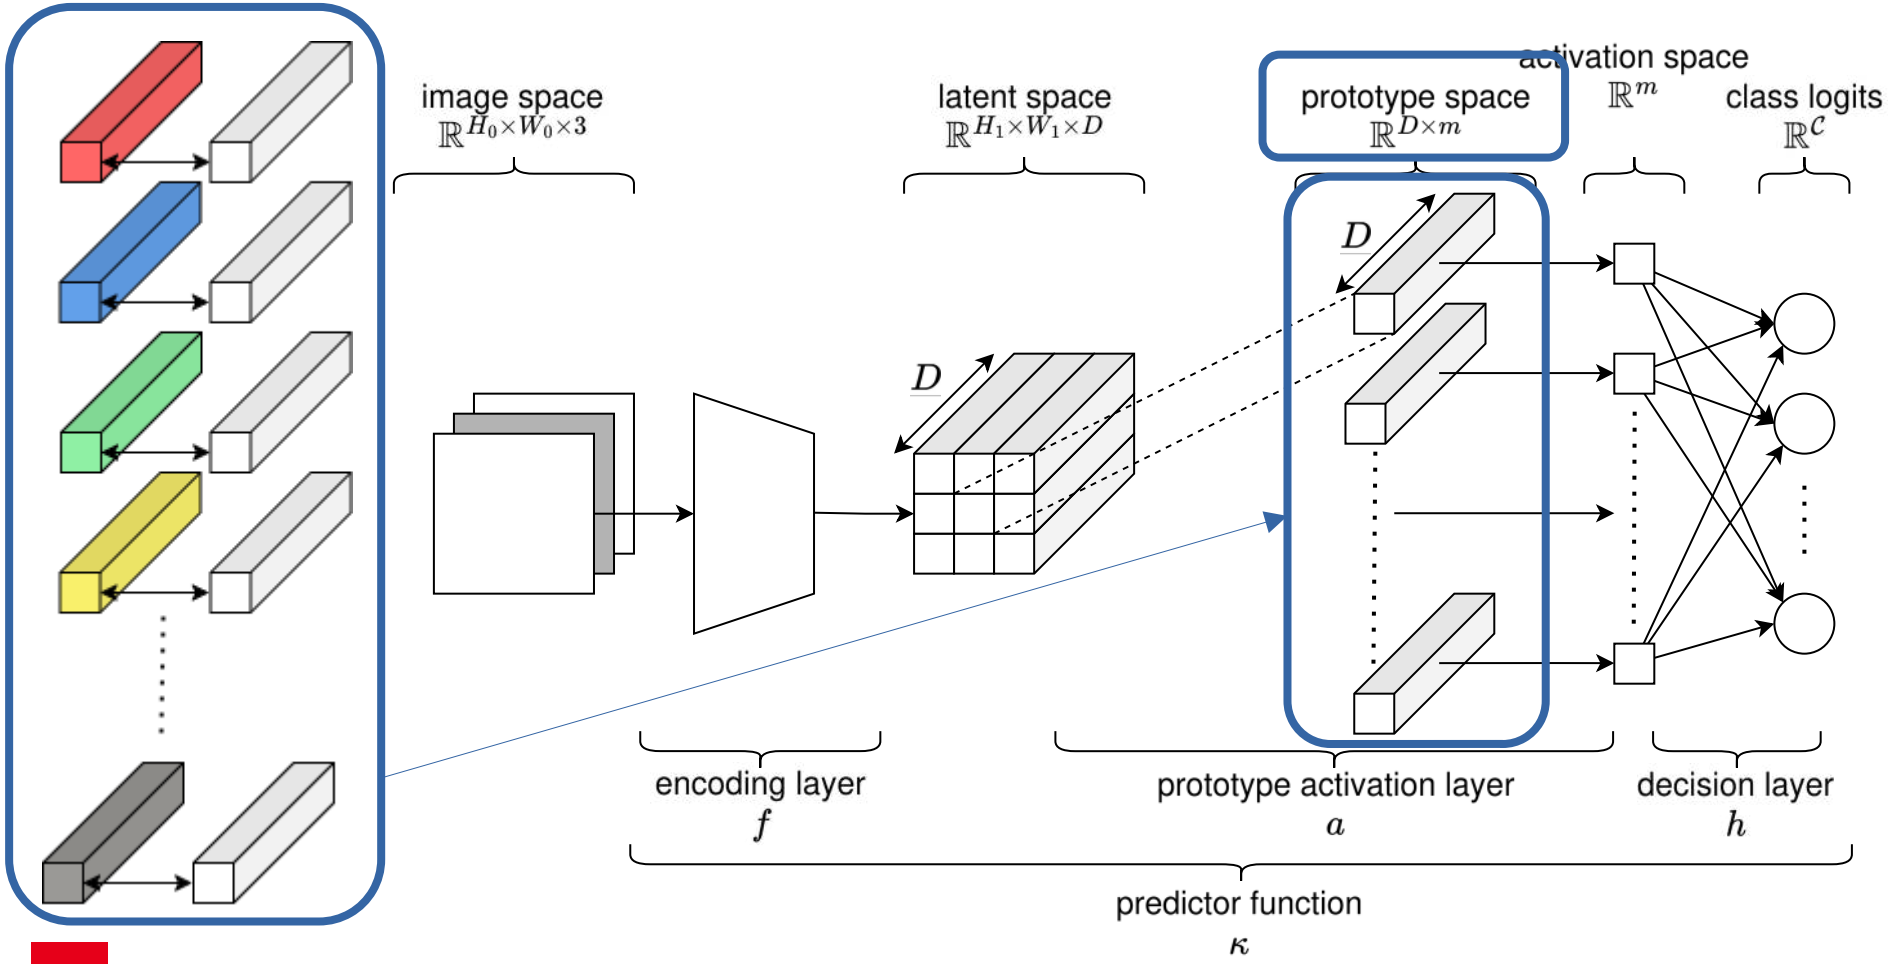
Explications Abductives pour Réseaux à base de prototypes

L'architecture permet de produire des explications dans différents espaces :



Explications Abductives pour Réseaux à base de prototypes

L'architecture permet de produire des explications dans différents espaces :



Explications Abductives pour Réseaux à base de prototypes

$$\forall \mathbf{x} \in \mathcal{F}. \quad \phi_{\mathcal{E}}(\mathbf{x}, \mathbf{v}) \Rightarrow (\kappa(\mathbf{x}) = c).$$



$$\forall \mathbf{x} \in \mathcal{F}. \quad \phi_{\mathcal{E}}(f(\mathbf{x}), f(\mathbf{v})) \Rightarrow (\kappa(\mathbf{x}) = c).$$

Avancement des travaux (2eme année)

***Travaux réalisés** :*

Exploration sur à quoi ressembleraient des explications abductives minimales dans le cadre des modèles à prototypes, et leur implémentation.

→ Soumission à ECAI 2025

***Travaux prévus** :*

Extension des travaux soumis pour avoir des explications plus compactes.

Collaboration active avec le laboratoire qui m'a accueilli au NII

Collaboration possible avec Politecnico di Milano pour appliquer les modèles existants de XAI, y compris le nôtre, sur des simulations de réacteurs nucléaires.

Vérifier formellement qu'un modèle a désappris des données.

Explorer comment étendre l'attribution de features par interprétation abstraite à des réseaux de neurones artificiels.